

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ KATEDRA

Detalus vaizdų panašumas naudojant trejetų tinklus

Fine-grained Images Similarity using Triplet-network

Kursinis darbas

Atliko:	4 kurso 6 grupės studentas	
	Andrius Butkevičius	(parašas)
Darbo vadovas:	dr. Vytautas Valaitis	(parašas)

Vilnius – 2020

TURINYS

ĮVADAS	2
UŽDAVINIAI	3
1. TREJETŲ IR SIAMO TINKLŲ TYRIMŲ LITERATŪROS ANALIZĖ	4
1.1. Gilieji konvoliuciniai neuronų tinklai	4
1.2. Trejetų tinklai.....	4
1.2.1. Architektūra	5
1.3. Siamio tinklas	6
1.3.1. Architektūra	6
1.4. Nefiksuoto dydžio vaizdai konvoliuciniuose tinkluose	7
2. ĮVERTINIMO FUNKCIJA	8
2.1. Pasirenkami duomenis įvertinimui analizuoti	9
3. TREJETŲ TINKLO VAIZDŲ ATPAŽINIMO TYRIMAS IR VERTINIMAS	10
3.1. Tikslumo metrikos	10
3.2. Treniravimo ir testavimo aplinka	10
3.3. VGG16 tinklo modelis	10
3.4. Tyrimo rezultatai	11
3.5. Vaizdai su prastais rezultatų palyginimais	12
3.6. Sprendimo būdai	13
4. REZULTATAI IR IŠVADOS	14
4.1. Rezultatai	14
4.2. Išvados	14
4.3. Ateities darbai	14
5. PRIEDAI	15
5.1. Žodynas.....	15
LITERATŪRA	16

Įvadas

Vaizdų panašumo įvertinimas ir lyginimas tampa vis plačiau naudojamas ir susilaukia vis didesnio dėmesio informacinių technologijų srityje. Visgi plėtojant šią technologiją ir siekiant išgauti kuo korektiškesnius rezultatus yra susiduriama su problemomis, nes kompiuteriui nėra lengva atskirti vizualius skirtumus ir objektų bruožų panašumus taip lengvai, kaip palyginus žmogui, kuris gali akimirskniu sugebėti atpažinti aplink jį esamus objektus. Vaizdų identifikavimas ar jų palyginimas plačiai taikomas šiuo metu, pvz.: vaizdinės tapatybės nustatymui, veido atpažinimui, esamos vietovės aptikimui pasitelkiant beipiločio orlaivio užfiksuotas reljefo nuotraukas, vaizdų radimui pasitelkiant paieškos sistemas. Norint sugebėti tai atpažinti ir klasifikuoti, yra pasitelkiami įvairūs tinklų modeliai ir jie treniruojami. Tam panaudojama tokie modeliai kaip Siamo arba trejetų tinklai. Šie tinklai susideda iš dviejų ar trijų vienetų ir lygiagrečių konvoliucinių neurono tinkle esančių atšakų, kurios tarpusavyje dalinasi svoriais, kurių dėka galima gauti aukšto lygio nuotraukų bruožų atvaizdavimą taip leidžiant panašioms nuotraukoms būti kuo arčiau sujungtoms viena su kita funkcijų erdvėje. Tuo metu nepanašioms vaizdams – būnant kuo toliau nuo teisingų nuotraukų. Rinkoje yra siūlomi įvairūs konvoliucinių neuronų tinklų modeliai, pvz.: Alexnet, VGGNet, GoogLeNet, ResNet [VMJ19]. Verta paminėti, kad visi šie modeliai turėjo efektyvius atpažinimo rezultatus ILSVRC. Taigi vis dažniau yra pasitelkiama prieš tai minėti trejetų tinklai, kurie optimizuoja bruožų atstumus erdvėje. Visgi sudėtingiausia problema išlieka dėl semantinio tarpo problemos, kuri atsiranda tarp žemos rezoliucijos nuotraukos pikselių užfiksuotų kompiuterinių sistemų ir aukšto lygio semantinių konceptų, kurias suvokia žmonės. Dėl to reikia rasti geresnių būdų, kaip sugebėti pateikti nuotrauką kompiuteriui ir gauti gilesnius jos semantinius bruožus. Todėl šio darbo tikslas yra pasiūlyti pasirinktą trejetų tinklų modelį [VMJ19], kuris sugebėtų atpažinti žmonių siluetus su pasirinktu duomenų rinkiniu. Palyginti pasirinktą modelį su kitais esamais rinkoje modeliais, palyginti rezultatus. Taip pat išskirti metrikas tam. Surasti su kuriais vaizdais pasirinktas modelis prastai vykdo atpažinimą ir kodėl.

Uždaviniai

1. Palyginti kitų neuronų tinklų modelių architektūras.
2. Pasiūlyti pasirinktą trejetų tinklų modelį bei atpažinti vaizdų panašumus iš pasirinkto duomenų rinkinio.
3. Išskirti metrikas pagal kurias galėtų analizuoti gautus rezultatus, panaudojant trejetų tinklų modelį.
4. Išskirti pasirinkto tyrimo rezultatų trūkumus ir išsiaiškinti galimas sritis ateities darbams.


1. Trejetų ir Siamio tinklų tyrimų literatūros analizė

1.1. Gilieji konvoliuciniai neuronų tinklai

Giliajame treniravime(mokyme), šis tinklas yra klasė iš giliųjų neuronų tinklų, kuri dažniausiai naudojama pritaikant vaizdų atpažinimą. Tai yra algoritmas, kuris įvestyje pasiima vaidą (nuotrauką ar paveiksluką), priskiria jam svorius ir jos bruožų tendencijas įvairiose įvesties dalyse ir sugeba pagal tai atskirti panašumus lyginant su kitomis įvestimis.

1.2. Trejetų tinklai

Trejetų tinklų modelis buvo pasiulytas 2014m., moksliniko Chang Wang [WSL⁺14]. Modelio veikimo principas susideda iš trijų identiškų konvoliucinių neuroninių tinklų šakų, kurie tapusavyje dalijasi gautais svoriais. Kai trejetų tinklas įvestyje gauna tris pavyzdžius, išvestyje yra grąžinama dvejų tarpinės reikšmės, kurios nurodo atstumus lyginamus su pagr dine įvestimi ir kitomis dvejomis įvestimis. Jų rezultatas yra vektoriai. 1 pav. parodytas abstraktus treniravimosi procesas, trejetų tinklų modelio.



1 pav. Trejeto tinklo treniravimosi procesas [YLL⁺19]

1.2.1. Architektūra

Trejetų tinklų modelis įvedimo dalyje reikalauja trijų įvesčių tuo pačiu metu. Kiekvienas jų turi savo pavadinimą ir reikšmę tinkle, pagrindinis x^a , pozityvus x^p , neigiamas x^n . Įvesties poros x^a ir x^p yra tos pačios kategorijos arba panašūs semantiškai įvestys. Tuo metu x^a ir x^n yra skirtingos kategorijos arba nepanašūs vaizdai. Pasitelkiant funkcijas yra apskaičiuojama jų semantiniai panašumai atstumo erdvėje (nes jie yra pateikiami kaip vektoriai). Ši funkcija yra vadinama nuostolių funkcija, jos galima funkcija aprašyta žemiau. Kur parametras α rodo tarpą tarp x^a ir x^p bei x^a ir x^n . N reiškia skaičių nusakantį kiek trejetų įvesčių yra pateikiama. Tikslas yra pasiekti, kad x^a ir x^p būtų mažiau nei x^a ir x^n [SKP15].

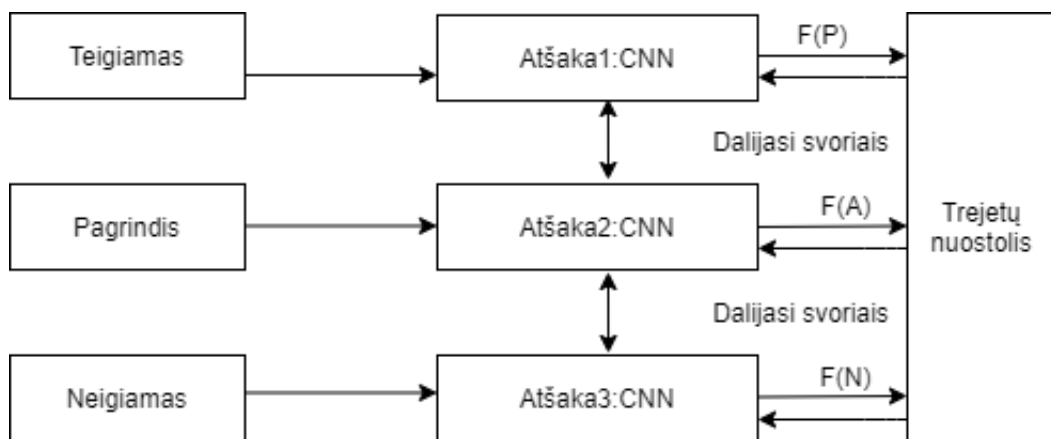
$$loss = \sum_{x=1}^N \max(d(x^a, x^p) - d(x^a, x^n) + \alpha, 0) \quad (1)$$

Kur d yra atstumo metrika, taip kad $d(x^a, x^p) < d(x^a, x^n)$, o N yra skaičius trejetų.

Nuostolių funkcija nusako, kaip gerai algoritmas modeliuoja pasirinktą duomenų rinkinį. Jei-gu prognozė rezultatui yra netiksli, ši funkcija grąžina didesnę reikšmę. Neuroninių tinklų modeliams galima naudoti ir kitas nuostolių funkcijas, priklausomai nuo duomenų rinkinio ir norimo rezultato gauti.

Alternatyvios nuostolių funkcijos. Artima šiai funkcijai yra ši lygtis. Ji naudoja kvadratinį Euklido [VMJ19] atstumą kaip atstumo metriką ir $\alpha > 0$, nurodanti ribą tarp dviejų vaizdų ir absoliučios sumos reikšmės.

$$loss = \sum_{x=1}^N [||x^a - x^p|| - ||x^a - x^n|| + \alpha] \quad (2)$$



2 pav. Trejeto tinklų veikimo principas kartu su neuroninių tinklų lygiagrečiomis atšakomis

Šis neuroninių tinklų architektūrinis sprendimas padeda apmokyti duomenų klasifikavimą išskaidant duomenis pagal panašumus ir skirtumus 2 pav.. Jų metu keli lygiagretūs gileji neuroniniai tinklai yra apmokami bei tuo pačiu metu jie dalijasi svoriais vieni su kitu treniruojant tinklą. Trejetų tinkle tikslas yra sukurti trejetus, kurie susideda iš pagrindinio p^a , teigiamio x^p , neigiamio

p^n – įvesties elementų. Pagrindinis elementas, tai kažkokia įvestis (nuotrauka, paveikslukas, muzikos įrašas ir t.t), kuriai mes bandome rasti atitikimą iš kitos įvesties. Teigiama įvestis – panašus elementas atitinkamai pagrindiniai nuotraukai. Tuo tarpu neigiamas elementas skaitosi tas, kuris neturi panašumų su pagrindine nuotrauka. Neuroniniai tinklai apskaičiuoja $\pi : f(\pi) \in$ Šie trys elementai yra įvedami nepriklausomai vienas nuo kito į tris identiškų giliuosius neuroninius tinklus, kurie dalijasi vienoda architektūra ir parametrais. Jų metu yra apskaičiuojami atstumai tarp šių elementų. Šiam apskaičiavimui yra naudojama kaip ir prieš tai minėta nuostolių funkcija.

Įmanomi rezultatai trjetų tinkle:

- Lengvas trejetas: trejetai, kurie turi nuostolį, su reikšme 0, nes $d(x^a, x^p) + \alpha < d(x^a, x^p)$
- Sudėtingas trejetas: trejetai, kurių neigiamumas yra arčiau pagrindinio negu teigiamo, $d(x^a, x^p) < d(x^a, x^p)$
- Pusiau sudėtingas trejetas: trejetai, kurių neigiamumas nėra arčiau teigiamo, tačiau vis tiek turi teigiamą nuostolį: $d(x^a, x^n) < d(x^a, x^p) + \alpha$

1.3. Siamo tinklas

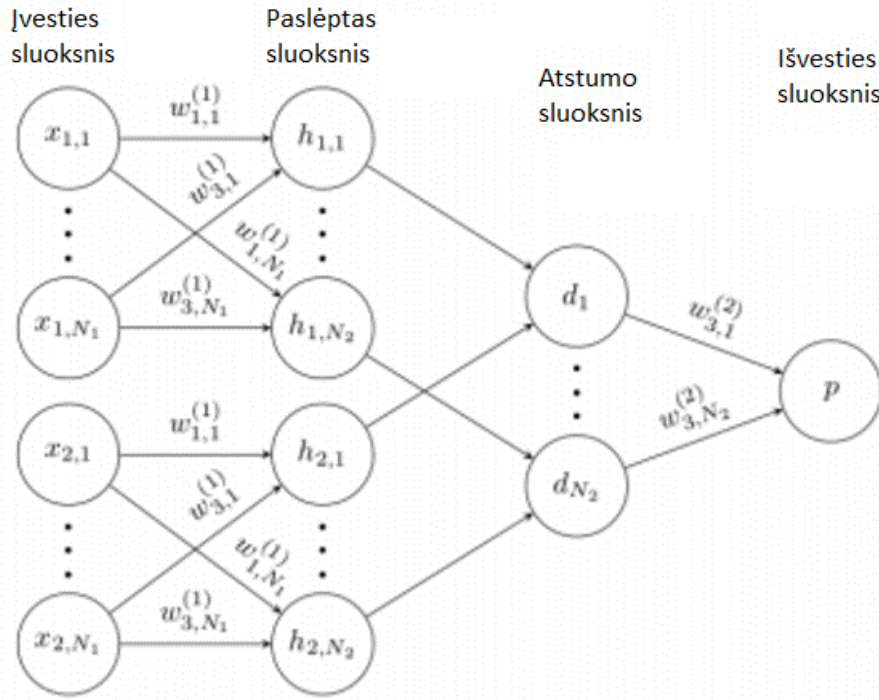
Pirma kartą publikuotas 1990 metais, autorių Bromely ir Yann LeCun, siekiant išspręsti parašo verifikavimo problema kaip vaizdo atitikimo problemą [BGL⁺90].

1.3.1. Architektūra

Tinklo modelis – neuronų tinklas turintis kelis ar daugiau identiškų neuroninių tinkle atšakas su vienodais parametrais [MKR16] (panašiai kaip ir trejetų tinklų modelyje). Šis modelis naudoja vienodus svorius vykdant tuo pačiu metu ir panaudojant du skirtingus įvesties vektorius, apskaičiuojant palyginamus išvesties vektorius. Šie vienodi tinklai su skirtingais įvesties duomenimis yra sujungti pagal energijos funkciją E . Ši matematinė funkcija apdoroja kai kurias metrikas tarp labiausiai išryškintų bruožų vaizdavimų kiekvienoje pusėje. Parametrai tarp šių vienodų tinkle yra apriboti, kad būtų vienodi. Svių apjungimas užtikrina, kad du labai panašūs vaizdai nebūtų tarp jų atitinkamų tinkle atšakų išvesti labai skirtinguose erdvės lokacijose. Taip pat, reikia paminėti, kad tinklas yra simetriškas, nesvarbu kuriam iš vienodų tinklų įvesime vaizdą, visada gausime tokias pačias metrikas. Standartinė išlaidų funkcija skirta mokymosi pavyzdžiui (x_1, x_2) yra pasiūlyta Hadselio.

$$L(W, (Y, x_1, x_2)) = \frac{1}{2}(1-Y)(D_w)^2 + (Y)\frac{1}{2}\max(0, m-D_w)^2 \quad (3)$$

, jei (x_1, x_2) yra panašios poros, ir $Y = 1$ kitu atveju. m yra riba nurodanti norimą slenkstį atstumui tarp x_1 ir x_2 jeigu jie nėra panašūs. Dėl laisvo sureguliojimo, dažniausiai taip yra sunkiau ištrenuoti trejetų tinklus negu Siamo tinkle. Tarkime x_1, x_2 yra pora vektorių, Y laikysime dvejetainę žymę, kur $Y = 1$ reiškia, kad vektoriai x_1, x_2 yra laikomi panašiais, $Y = 0$ - priešingu atveju. D_w - parametrizuota atstumo funkcija (Euklido).



3 pav. Siamo tiklų modelis

1.4. Nefiksuoto dydžio vaizdai konvoliuciniuose tinkluose

Gilieji konvoliuciniai tinklai reikalauja fiksuoto dydžio įvesties vaizdų. Tačiau realiaame gyvenime nuotraukų ar paveikslukų dydžiai nėra fiksuoti ir varijuoja plačiai.

Jeigu yra bandoma primiktynai pakeisti į reikiama dydį, nuotrauką karpant ar deformuojant, informacija, patalpinta nuotraukose bus prarasta. To pasekoje tikslumas nuotraukų klasifikacijos ar objektų identifikavime bus sumažintas ir nepataisomai sugadintas. Nors neuroniniuose tinkluose, konvoliuciniai sluoksniai nereikalauja fiksuoto dydžio įvesties ir geba generuoti specifinius bruožus vaizdo iš bet kokio dydžio nuotraukų. Visgi, pilnai sujungti sluoksniai privalo turėti fiksuoto dydžio įvestį dėl jų pačių apibrėžimo. Dėl to apribojimas fiksuoto dydžio nuotraukų ateina tik iš pilnai sujungtų sluoksnių reikiamos ypatybės. Viena iš šios problemos sprendimo būdų yra naudoti erdvinės piramidės talpinimą [HZR⁺15], tokiu būdų galima bandyti identifikuoti vaizdus, kurių rezoliucijos yra skirtingos.

Šis būdas ištraukia vaizdo bruožus iš bruožų žemėlapių (angl. map) per 4×4 , 2×2 ir 1×1 kvadratų tinklelio. Tada SPP sluoksnis pateikia $16 + 4 + 1 = 21$ skirtingus aruodus (angl. bin) ir gauna fiksuoto dydžio išvestį kviečiant kiekvieną bloką. Po erdvinės piramidės talpinimo būdo išgavimo, bet kuris bruožų žemėlapis gali generuoti 5736 dimensijų ypatybių vektorius, kur $5736 = 24 \times 26$. SPP sluoksnis pasiima ypatybes ir generuoja fiksuoto dydžio išvestis, kuris galiausiai yra perduodamas į pilnai sujungtus sluoksnius.

2. Įvertinimo funkcija

Kelios įvertinimų metrikos yra naudojamos: panašumo tikslumas bei *score-at-top-K*, kai $K = 30$. Panašumo tikslumas yra išreiškiamas procentaliai pagal tai, kiek trejetų buvo korektiškai sureitinguota. Sakykime, kad turime trejetą, su šiais įvesties parametrais $tt = (x^a, x^p, x^n)$, kur x^p turėtų būti arčiau(panašesnis)šalia x^a . Laikant, kad x^a yra įvesties užklausa, žiūrime į rezultatus kitų įvesties duomenų. Jeigu x^p yra reitinguojamas aukščiau nei x^n , tai tada teigiame, kad atitinkamas trejetas yra sureitinguotas teisingai. Kita mums reikalinga metrika, kuri buvo užsiminta anksčiau *score-at-top-K*. Jis nusako skaičių teisingai sureitinguotų trejetų bei atimant iš jo skaičių, kuris nusako neteisingai sureitinguotus trejetus iš pogrupio trejetų, kurių reitingas yra didesnis, nei kintamasis K . Pogrupis yra pasirenkamas tokia tvarka: kiekvienam užklausoos paveikslėliui iš duomenų aibės, ištraukia 1000 naujų paveikslėlių iš tos pačios teksto užklausoos ir yra bandoma taip reitinguoti juos, pasitelkiant išmoktas metrikas. Jei trejetų reitingas yra aukštesnis negu K , jeigu jo x^p arba x^n tada yra tarp geriausiai reitinguojamų K kaimynų iš užklausoos su paveikslėliais x^a .

2.1. Pasirenkami duomenis įvertinimui analizuoti

Kadangi darbo tema susijusi su detaliu vaizdų atpažinimu, kuris negali būti charakterizuotas pagal vaizdų kategorijų žymes, literatūroje buvo surasta informacijos, panaudojant trejetų duomenų rinkinys norint įvertinti nuotraukų panašumus su skirtingais modeliams [WSL⁺14]. Buvo paimta 1000 populiariausių teksto užklausų su atrinktais trejetais (x^a, x^p, x^n) su Google 50 paieškos rezultatų kiekvienai užklausiai [WSL⁺14].

Atpažinimo efektyvumas pagal metrikas yra nurodytas 1 lentelė ir 2 lentelė. "DeepRanking", kuris paminėtas buvo literatūroje, yra gilusis reitingavimo modelis treniruotas su 20% neigiamais pavyzdžiais. Visgi pastebima, kad joks vaizdų atpažinimo modelis be treniravimo nepasiekia gerų rezultatų ir nėra dinamiškai prisitaikantis prie naujo duomenų rinkinio, kuris priklauso kitoms vaizdų klasifikacijos kategorijoms. L1HashKCPA pasiekė visai neblogą rezultatą su ganėtinai mažai dimensijų, tačiau jo našumas yra ganėtinai prastesnis negu "DeepRanking" metodo.

Metodas	Tikslumas	Score-30
ConvNet	82.8%	5772
Single-scale Ranking	84.6%	6245
OASIS on Single-scale Ranking	82.5%	6263
Single-Scale & Visual Feature	84.1%	6765
DeepRanking	85.7%	7004

1 lentelė. Tikslumo metrikų rezultatai (1)

Metodas	Tikslumas	Score-30
Wavelet	62.2%	2735
Color	62.3%	2935
SIFT-like	65.5%	2863
Fisher & Visual Feature	67.2%	3064
HOG	85.7%	7004
SPMKtexton1024max	66.5%	3556
L1HashKPCA	76.2%	6356
OASIS	79.2%	6813
Golden Features	80.3%	7165
DeepRanking	85.7%	7004

2 lentelė. Tikslumo metrikų rezultatai (2)

3. Trejetų tinklo vaizdų atpažinimo tyrimas ir vertinimas

3.1. Tikslumo metrikos

Šiame darbe buvo naudojama tikslumo metrika (4), kuri naudojama dvejetainių klasifikatorių vertinime.

$$accuracy = \frac{\sum \text{Teigiamas} + \sum \text{Neigiamas}}{\sum \text{Visa populiacija}} \quad (4)$$

Kadangi yra labai retas atvejis, kad $d(x_a, x_p)$ būtų lygus $d(x_a, x_n)$, galima laikyti, kad $\sum \text{Teigiamas}$ yra lygus $\sum \text{Neigiamas}$. Del to, galima skaičiuoti tik $\sum \text{Teigiamas}$ iš visų įvesties trejetų sumos N_t treniruojamame rinkinyje. Galutinė lygtis (5), kuri naudojama tikslumui lyginti.

$$accuracy = \frac{\sum d(x_a, x_p) + \sum d(x_a, x_n)}{N_t} \quad (5)$$

3.2. Treniravimo ir testavimo aplinka

Trejetų tinklo modelis buvo treniruojamas naudojant Lenovo Y-700 kompiuterį su šiomis specifikacijomis: CPU i7 6700K (4 branduolių), 8GB RAM, GPU Nvidia GTX 960m (4GB RAM). Norint pasileisti trejetų modelį būtent šiam kompiuteriui (priklausomai nuo mašinos tai gali skirtis) buvo atsisiųsta Nvidia CUDA programinė įranga su tikslu, kad modelio treniravimas būtų vykdomas pasitelkiant vaizdo plokštę, o ne procesorių.

Priežastis kodėl buvo pasirinkta vaizdo plokštė yra todėl, kad gilusis mokymasis yra intensyvi skaičiavimo užduotis. Į gilųjį mokymasi įeina didžiuliai matricių skaičiavimai (ypač sandauga) ir kitos operacijos, kurios gali veikti paraleliai todėl vaizdo plokštė ateina į pagalbą, nes viena vaizdo plokštė gali turėti tūkstančius branduolių, tuo metu procesorius turi žymiai mažiau branduolių, nors jie ir žymiai greitesni negu vaizdo plokštės [KK18].

Pasirenkamas trejetų tinklų modelis yra implementuotas naudojant Tensorflow karkasą, Python 3.5.1. Vaizdų duomenų rinkinyje buvo 3884 nuotraukos, kuriose jau buvo surikiuotos teisinga eilės tvarka, kur pirma nuotrauka pagrindinė, antra nuotrauka - teigiama (kuri yra panaši į pagrindinę) bei neigiama (nepanaši į pagrindinę nuotrauką) ir tokia eilės tvarka yra išsidėstę visos kitos nuotraukos. Ištreniravus šiuos duomenis yra bandoma analizuoti modelio tikslumą imant vaizdų pavyzdžius iš testinio duomenų rinkinio.

3.3. VGG16 tinklo modelis

Šiame darbe, žmonių siluetų atpažinimui yra naudojamas trjetų tinklų modelis [VMJ19]. Modelis naudoja modifikuota nuostolių funkciją:

$$loss = \sum_{i=1}^{N_t} \left[\ln\left(-\frac{\sum_{j=1}^N (f_o^a - f_o^p)^2}{\beta} + 1 + \epsilon\right) + \ln\left(-\frac{\sum_{j=1}^N (f_o^a - f_o^n)^2}{\beta} + 1 + \epsilon\right) \right] \quad (6)$$

Kur f_o^a yra ModelNN išvestis pagrindiniai nuotraukai, f_o^p ir f_o^n yra ModelNN išvestys teigia-

mai ir neigiamai nuotraukoms. N yra išvesties vektorių dimensijos, o trejetų skaičius treniravimo duomenų rinkinyje. ϵ yra koks nors mažas skaičius, pvz.: 10^{-6} . Nuostolių funkcija yra 0, kai teigiama ir neigiama įvestys yra maksimaliu atstumu viena nuo kitos. Šio modelio architektūra naudoja VGG16 tinklo bazės sluoksnius klasifikavimui todėl tik labai panašūs vaizdai gali būti naudojami duomenų treniravimui tam, kad pagerinti tinklo atlikimą bei išsaugoti skaičiavimo išteklius.

VGG16 yra konvoliucinių neuroninių tinklų modelis, išrastas K. Simonian ir A. Zisserman (Oksfordo universitetas). Modelis sugeba pasiekti 92.7% top-5 testų tikslumą (treniravimo duomenys pasiimti iš ImageNet). VGG16 buvo treniruojamas savaitę iš savaitės naudojant Nvidia Titan Black vaizdo plokščių šeimas.

3.4. Tyrimo rezultatai

Šiame darbe buvo bandyta atpažinti detalius vaizdus, naudojant vaizdų duomenų rinkinį CUHK01. Šiame duomenų rinkinyje yra pavaizduota 3884 viešose vietose einančių pėsčiųjų kadrai. Todėl naudojant šį duomenų rinkinį buvo analizuojama, kaip su pasirinktu trejetų modeliu seksis atpažinti skirtingus žmogaus kadrus, kurie buvo nufotografuoti įvairiai - iš kelių pusių, iš nugaros ir priekio, esant skirtingai žmogaus eisenos pozicijai, skirtingam apšvietimui ir kontrastams, įsiterpiančiams kitiems objektams prie pėsčiojo.

Ištreniravus trejetų tinklą su pasirinktu duomenų rinkiniu ir pradėjus testuoti jo rezultatus, gavau 85,7% tikslumo rezultatą. Tai yra gan aukštas įvertinimas, nes atpažinti to paties pėsčiojo skirtingus kadrus nėra lengviausia užduotis, nes susiduriame su kliūtimis, aprašytomis anksčiau. Jeigu palyginsime kaip sekėsi kitiems neuroninių tinklų modeliams atpažinti būtent šį duomenų rinkinį, turime tokius rezultatus: 90.4% , kur neuronų tinklų modelį sukūrė mokslininkai iš Kinijos Mokslo ir Technologijų universiteto. [ZLZ⁺19]



4 pav. Žmogaus skirtingi eisenos kadrai

Taip pat, žemiau pateikiu kitus rezultatus, gautus su kitais neuroniniais tinklų modeliais:

Modelis	Tikslumas
Spindle	94.4%
PSE	86.6%
Part-Aligned	94.4%
AACN	96.7%

3 lentelė. CUHK01 duomenų tikslumo rezultatai

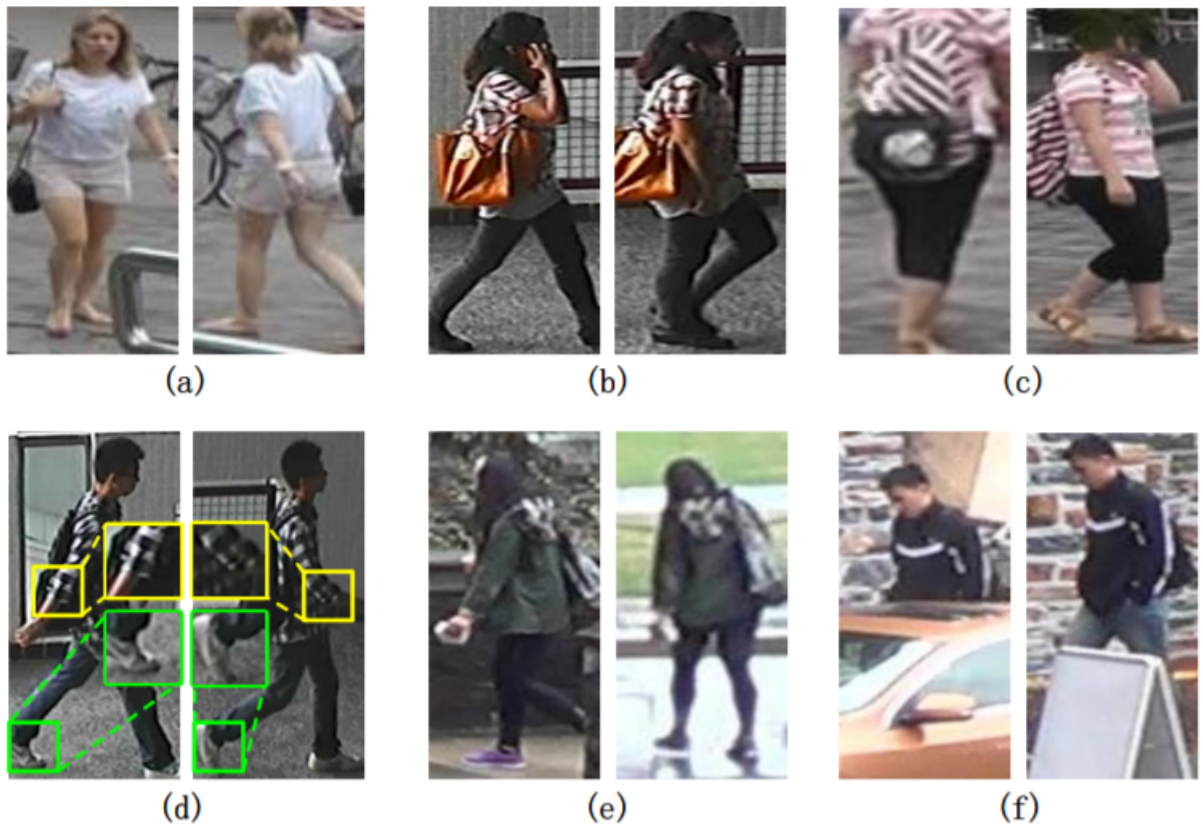
3.5. Vaizdai su prastais rezultatų palyginimais

Visgi ne visi vaizdai buvo tisingai palyginimi ir nustatomi trejetų tinklo modelio. Todėl šiame darbe buvo ieškoma ir nagrinėjama, kurios vaizdų įvestis turėdavo prastus rezultatus bei buvo bandoma išsiaiškinti kas sukeldavo prastus rezultatus.



5 pav. Blogai identifikuotos vaizdų poros

Dauguma nuotraukų, kurios buvo blogai identifikuotos skirėsi viena nuo kitos spalvų intensyvumu, skirtingomis spalvomis. Pavyzdžiui matome, kad tiek pirmoje ir antroje nuotraukų porose įsiterpusi nauja žalia spalva (žalumos objektai) leidžia manyti, kad tai yra viena iš priežasčių, kodėl nepavyko tinkamai identifikuoti to paties asmens kadrus. Taip pat antroje poroje matome, kad žmogaus judėjimo kampas į objektyvą skiriasi, o ir nuotraukų šviesos intensyvumas yra kitoks. Todėl tai leidžia daryti prielaidą, kad ir vaizdų palyginimo rezultatai bus prasti, jei nuotraukos bus nufotografuotos ne kokybiškai - apšvietimo skirtumai, netvarkingas fonas ar atsiradusi okliuzija [ZLZ⁺19].



6 pav. Sunkiai identifikuojamų nuotraukų poros

Viršuje esančios žmonių nuotraukų poros yra sudėtingai identifikuojamos dėl įvairių priežasčių: a) dėl skirtingo objektyvo kampo, b) skirtingos žmogaus pozos, c) prastos nuotraukos kadro užfiksavimo (susiliejas vaizdas), d) ne vienodame lygyje esančios žmogaus kūno dalis, atsiradusios dėl jo judėjimo, e) netvarkingas fonas, f) okliuzija.

3.6. Sprendimo būdai

Visgi ieškant literatūroje informacijos, kurioje būtų aprašyti sprendimo būdai, kai lyginami vaizdai vienas su kitu yra nekorektiški bruožų atžvilgiu, tačiau panašūs ar priklauso tai pačiai klasei, yra siūlomi keli sprendimų būdai. Pavyzdžiui, ypatybių fokusavimą nukreipiant į lokalias detales buvo sukurtas nesudėtingas suskirstymas asmens nuotraukos į kelias fiksuotas ir nekintančias dalis, pavyzdžiui į horizontales juosteles ir taip mokantis lokalių nuotraukų bruožų atpažinimo. Visgi, kaip tyrimai iš literatūros nurodė toks skirstymas prastai lygina identifikuojamo asmens kūno dalis [ZLZ⁺19]. Kituose tyrimuose ir bandymuose buvo bandoma naudoti žmogaus pozą, tokiu būdu identifikuojant skirtingas kūno dalis: kojas, rankas, veidą. Tačiau ir toks atpažinimo metodas yra prastas, kad gauti norimus rezultatus, nes identifikuoti tas pačias žmogaus kūno dalis iš skirtingų žmogaus padėčių kelia problemų dėl asmens skirtingos judėjimo pozos nuotraukos [ZLZ⁺19].

4. Rezultatai ir išvados

4.1. Rezultatai

1. Buvo lyginimi kiti trejetų tinklai rinkoje, nagrinėjami jų rezultatai.
2. Buvo pasiūlytas trejetų tinklų modelis, kuris sugebėjo teisingai atpažinti 85.7% vaizdų, palyginus su kitais rinkoje esančiais modeliais, kurių rezultatai sviruoja nuo 86.6% iki 96.7%, pasirinktas modelis turėjo konkuruojančius rezultatus, nors ir ne pačius geriausius.
3. Buvo išskirtos metrikos pagal ką reitinguoti vaizdų atpažinimą.
4. Aprašyti tyrimo rezultatai, rastos problemos, dėl kurių yra sudėtinga labai gerai atpažinti nuotraukos, viena iš priežasčių, žmogaus eisenos trajektorijos skirtumai tarp lyginamų vaizdų.

4.2. Išvados

1. Yra sudėtinga lyginti trejetų ir Siamo modelius, nes jų architektūra gali varijuota pagal tai kaip modelis yra įgyvendintas. Teisingiau yra lyginti specialius jų sukurtus modelius vienas su kitu.
2. Pasirinktas trejetų tinklų modelis parodė neblogus rezultatus identifikuojant žmonių eisenos kadrus.
3. Identifikuojant žmones nuotraukose susiduriama su rimtomis problemomis, kai to paties žmogaus nuotraukos skiriasi dėl pašalinių priežasčių. Kas lemia kad žmonių identifikacija yra sudėtingas procesas, kuris tam tikroms nuotraukoms neturi sprendimo būdų.

4.3. Ateities darbai

1. Išbandyti kitą trejetų modelį su pasiūlytais būdais, kurie gebėtų dar geriau atpažinti žmonių siluetus
2. Atlikti atpažinimo rezultatų analizę su kitais neuronų tinklais.
3. Ištestuoti su daugiau duomenų rinkinių. Stebėti ir lyginti rezultatus
4. Iškelti savo palyginimo metodą, kuris gebėtų teisingai identifikuoti žmonių siluetus nuotraukose.

5. Priedai

5.1. Žodynas

- Svoris(angl. weight) - parametras neuroniname tinkle, kuris transformuoja įvesties duomenys paslėptuose sluoksniuose.
- Nuostolių funkcija(angl. loss function) - funkcija, padedanti optimizuoti svorius, taip sumažinant neatitikimų nuostolius.
- Detalieji vaizdai(angl. fine-grained) - detalūs vaizdai. Vaizdo klasifikavimo užduotyse, tai yra įvesties vaizdai, kuriuos yra sudėtinga išskirti klasėms, pvz.: identifikuojant skirtingų markių automobilius.
- Aktyvacijos funkcija(angl. activation function) - funkcija, skirta nustatyti ar neuronas turi būti aktyvuotas, skaičiuojant svorių sumą bei pridedant postūmio parametą.
- Postūmis(angl. bias) - papildomas parametras neuroniniuose tinkluose, kuris padeda koreguoti išvesti kartu su svorių įvesties suma, skirta neuronams perduoti. Taip pat šis parametras leidžia perstumti aktyvacijos sumą nuo kairės į dešinę.

Literatūra

- [BGL⁺90] Jane Bromley, Isabelle Guyon, Yann LeCun, Eduard Sickinger ir Roopak Shah. Signature verification using a siamese time delay neural network, 1990.
- [HZR⁺15] Kaiming He, Xiangyu Zhang, Shaoqing Ren ir Jian Sun. Spatial pyramid pooling in deep convolutional networks for visual recognition, 2015.
- [YLL⁺19] Xinpan Yuan, Qunfeng Liu, Jun Long, Lei Hu ir Yulou Wang. Deep image similarity measurement based on the improved triplet network with spatial pyramid pooling, 2019.
- [KK18] Amr Kayid ir Yasmeeen Khaled. Performance of cpus/gpus for deep learning workloads, 2018.
- [MKR16] Iaroslav Melekhov, Juho Kannala ir Esa Rahtu. Siamese network features for image matching, 2016.
- [SKP15] Florian Schroff, Dmitry Kalenichenko ir James Philbin. Facenet: a unified embedding for face recognition and clustering, 2015.
- [VMJ19] Vytautas Valaitis, Virginijus Marcinkevicius ir Rokas Jurevicius. Learning aerial image similarity using triplet networks, 2019.
- [WSL⁺14] Jiang Wang, Yang Song, Thomas Leung, Chuck Rosenberg, Jingbin Wang, James Philbin, Bo Chen ir Ying Wu¹. Learning fine-grained image similarity with deep ranking, 2014.
- [ZLZ⁺19] Zhizheng Zhang, Cuiling Lan, Wenjun Zeng ir Zhibo Chen. Densely semantically aligned person re-identification, 2019.